

Label Noisy Representation Learning

Wentao Mo¹

¹Department of Machine Intelligence
Peking University

2021 年 4 月 23 日

- 1 Noise Transition Matrix, Forward/Backward Correction
- 2 Estimate Noise Transition Matrix T

LNRL in Chart

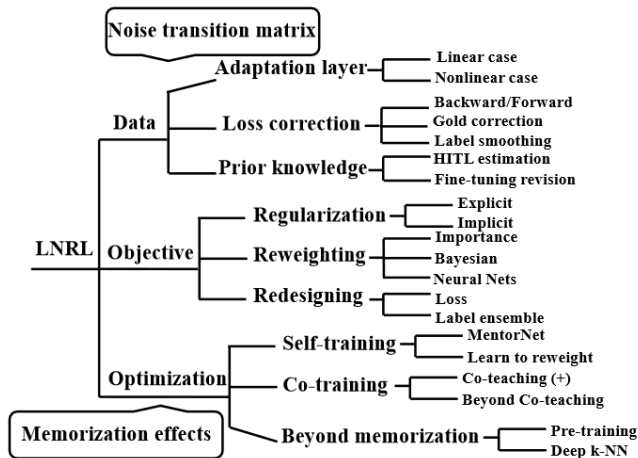


Fig. 2. A taxonomy of LNRL based on the focus of each method. For each technique branch, we list a few representative works here.

定义

(Noise transition matrix) Suppose that the observed noisy label \bar{y} is drawn independently from a corrupted distribution $p(X, \bar{Y})$, where features are intact. Meanwhile, there exists a corruption process, transition from the latent clean label y to the observed noisy label \bar{y} . Such a corruption process can be approximately modeled via a noise transition matrix T , where $T_{ij} = p(\bar{y} = e_j \mid y = e_i)$

两种经典的 (合成) 噪声转移矩阵, 对称 flipping/配对 flipping

$$\begin{bmatrix} 1 - \tau & \frac{\tau}{n-1} & \cdots & \frac{\tau}{n-1} \\ \frac{\tau}{n-1} & 1 - \tau & & \frac{\tau}{n-1} \\ \vdots & & \ddots & \vdots \\ \frac{\tau}{n-1} & \frac{\tau}{n-1} & \cdots & 1 - \tau \end{bmatrix} \quad \begin{bmatrix} 1 - \tau & \tau & 0 & 0 \\ 0 & 1 - \tau & \tau & 0 \\ \vdots & & \ddots & \vdots \\ 0 & & & \tau \\ \tau & 0 & \cdots & 1 - \tau \end{bmatrix}$$

实际中噪声不一定形式这么好/对称.

Remark 在合成噪声和实际噪声之间存在 domain gap.

Estimate Noise Transition Matrix T

定义

后向矫正

$$\ell^{\leftarrow}(f(x), \bar{y}) = [T^{-1}\ell_{y|f(x)}]_{\bar{y}} \quad (1)$$

可以证明后向矫正 loss 是 clean label loss 的无偏估计.

定义

前向矫正

$$\ell^{\rightarrow}(f(x), \bar{y}) = [\ell_{y|T^{\top}f(x)}]_{\bar{y}} \quad (2)$$

可以证明前向矫正 loss 和 clean label loss 上有相同的极小值.

Estimate Noise Transition Matrix T

- ① (Patrini et al., 2017) 提出一个两阶段训练. 首先使用 noisy data 训练网络, 再获得一个 T 的估计, 再重新训练网络, 使用 T 校正的 loss.
- ② (Hendrycks et al., 2018) 提出了 Gold 校正来处理严重噪声. 关键思路是, 假设一部分数据是可信的且可用的, 比如有一些专家来得出的 trusted set D . 他们使用 D 来估计 T , 再用前向矫正来训练 DNN, 这就是 GLC.
- ③ 使用 Label Smoothing. 本质上是后向矫正, 且 $T^{-1} = (1 - \alpha)I + \frac{\alpha E}{L}$

Regularization: Explicit

- ① (Azadi et al., 2016) 提出了一种正则化项 $\Omega_{\text{aux}}(w) = \|Fw\|_g$ 其中 $\|\cdot\|_g$ 是 group norm, $F^\top = [X_1, \dots, X_n]$, $X_i = \text{Diag}(x_i)$, 鼓励稀疏性. 这会鼓励一小部分 clean data 来 control model.
- ② (Berthelot et al., 2019) 提出了 MixMatch 来进行 SSL. 其中的一个关键部分是 Minimum Ent. Reg.(MER), 也是一种显式正则化. MER 提出于 (Grandvalet & Bengio, 2005), 关键 idea 是把 CE 加入一个正则项, 鼓励在 unlabeled data 上给出 high-confidence 的输出, 具体地, 最小化在 unlabeled 数据上的熵.
- ③ 类似于 MER, psedo-label 方法 (D.-H. Lee, 2013)(i.e. label guessing) 进行隐式的 ent. 最小化. 具体上讲, 首先计算模型 (通过各种 augmentation) 预测的类型分布, 再通过 temperature sharpening func. 来最小化 label dist. 的熵.

(Miyato et al., 2018) 提出了一个 virtual adversarial loss, 是一种新的衡量条件标签分布 (i.e., $p(y|x)$) 的局部平滑度的方法. 具体地, 他们要求输出分布在输入点附近各向同性地平滑, 通过把模型在其最各向异性的方向上选择性地平滑. 使得模型对输入不敏感. 使用 VA direction, 类似 FGSM/PGD 但利用了二阶梯度的估计.